中文酒店评论情感分析：传统基线、提示学习与模型微调的效果及成本比较

课程：自然语言处理（2026—2027 秋季学期） 组长学号 / 姓名：20245726 / 刘广徽 方向：C——提示与微调对比

成员与分工：刘广徽（组长：选型、方案、LoRA、融合、对比与报告）；杨函齐（MacBERT全参微调、TF-IDF）；李嘉谊林（零样本、少样本）。三人学号依次为20245726、20246005、20245816；完整职责见第⑧节。

提交日期：2026年10月29日 仓库地址：liuguanghui520/NLP 演示录屏：百度网盘视频，提取码9vxp（111.317秒；实测分享可用）

摘要

比较TF-IDF逻辑回归、MacBERT及Qwen3-1.7B零 / 四样本、LoRA。数据按6210/776/777划分，验证Macro-F1选优，训练重复3种子。五方案原测试Macro-F1为86.10%、91.52%、62.56%、76.10%、91.12%。MacBERT、LoRA平均延迟6.13、59.06ms。两机复验中TF-IDF、MacBERT预测一致；零样本F1变化1.82个百分点，四样本、LoRA变化0.18、0.19个百分点。BF16生成存在跨机得分和token排序差异，受控后端未消除分歧。MacBERT兼顾效果、成本及本次跨机稳定性，LoRA适配有效，零样本需结合环境解释。

① 问题定义与背景

酒店评论同时包含卫生、位置、服务、价格等多个方面，既可能明确表达满意或不满，也可能夹杂比较、转折和酒店回复。本项目将评论整体情感划分为负面0或正面1，面向需要批量整理住客反馈、辅助发现差评的使用场景。当前成果是课程实验与可复现工程入口，尚未部署为实际业务服务。

研究问题是：在相同冻结数据上，传统稀疏特征、预训练编码器、生成式提示和参数高效微调分别取得怎样的分类效果？增加示例或监督训练是否改善Qwen表现？效果提升对应多少训练时间、推理延迟和资源占用？

成功判据采用可检查的工程及实验条件：五条路线均完成同一测试集的完整预测；按验证Macro-F1选参；至少完成一组参数比较与三类错误归因；保存配置、日志、逐样本输出和可独立重算的指标；同时报告延迟与资源。分类效果通过基线间差值评价，没有事后补设一个“达到某分即成功”的门槛。4070独立环境复现逐样本一致；4060已完整完成11次预测，85条跨机输出差异作为硬件稳定性实验结果报告。源码、冻结依赖及统一入口用于独立复核主要结果。

② 相关工作与方案选型

2.1 五种实验方案

按作业给出的技术路线，本项目组织五种情感分类方案，依次考察局部统计特征、预训练上下文表示、任务提示、示例引导和监督适配。它们共享冻结的数据划分与正式标签，通过统一评估比较效果和成本。

方案	表示与输出方式	如何适应情感任务	在实验中的作用
字符n-gram＋TF-IDF＋逻辑回归	字符片段转换为稀疏向量，由线性分类器输出0/1	在训练集拟合特征和分类器	传统非大模型基线，衡量轻量方案的能力
MacBERT全参数微调	中文预训练编码器提取上下文表示，分类头输出两类分数	更新编码器、嵌入层和分类头全部参数	监督训练的预训练编码器基线
Qwen3-1.7B零样本	读取中文任务说明，生成0/1	不更新权重，不提供任务示例	观察原始模型对任务说明的直接响应
Qwen3-1.7B固定四样本	在同一任务说明前加入正负各两条标注示例	不更新权重，通过上下文展示判断与输出格式	观察示例引导带来的改善
Qwen3-1.7B普通LoRA	同一生成式基座，以标注答案训练增量矩阵	冻结基座、更新LoRA参数，推理不放示例	观察参数高效监督适配的效果与代价

TF-IDF与MacBERT均直接执行分类；Qwen三种方案通过生成标签完成分类。Qwen三种方案共用基座，但提示格式、示例数量和监督方式存在实际差异，后续按完整配置比较。

2.2 为什么选择这些模型和工具

TF-IDF字符特征减少中文分词词典依赖，n-gram保留局部搭配，逻辑回归提供简单稳定的分类参照[1]。MacBERT由哈尔滨工业大学与讯飞研究院联合实验室HFL提出，面向通用中文NLP，采用纠错式掩码等预训练设计；原研究包含ChnSentiCorp分类评测，因此具有任务相关的研究基础[2]。本项目加载预训练权重后全参训练，当前路线不再使用早期的随机初始化设想。

选择Qwen3的实践起点是B站LoRA教程的推荐，B站LoRA微调教程（BV1waZ2YDEcp）。这一系列支持中文等多种语言、提供多种参数规模和开放权重，并支持Transformers加载，便于本地实验。Qwen3还支持思考与非思考模式切换，本任务只需输出标签，因此关闭思考，控制额外生成[3]。结合RTX 4070 Laptop的8GB显存条件采用1.7B版本；实际运行已验证当前提示和普通LoRA配置可行。

LoRA通过冻结基座、训练低秩更新矩阵来减少可训练参数及对应训练状态[4]。采用普通LoRA使对照集中于秩、注入模块、学习率等设置，未引入量化变量。LLaMA-Factory的WebUI便于首次以可视化方式理解和配置微调流程，是选择该工具的重要原因[5]。后续保留实际配置与日志，使用PEFT、Transformers和PyTorch执行模型相关工作，SwanLab跟踪LoRA实验；统一评估使用项目脚本。BERT与TF-IDF搜索实际为脚本枚举，未将工具安装验证写成Optuna正式搜索。

2.4 选型边界：为什么包含微调、不引入RAG

作业方向C要求比较提示与微调，因此同时保留无需更新权重的提示、MacBERT全参微调和普通LoRA；TF-IDF提供非大模型基线。当前任务只判断给定评论的整体情感，不依赖外部事实检索，故不增加RAG及其检索库、召回和引用链路。没有另造两个未运行的备选方案实验；选型通过上述五路线的真实对照说明。

2.3 三个课程原理点：解释、实验与证据

本节原理与参数增益采用4070原始实验；跨硬件稳定性另由两机完整复验及验证诊断检验。

原理一：分词粒度与n-gram特征改变可学习的局部信息（第2、7讲）。 字符n-gram统计相邻字符片段，词n-gram依赖分词边界；TF-IDF降低高频通用片段权重，线性分类器学习片段与情感标签的关联。这是稀疏特征分类，不是用n-gram概率直接计算句子困惑度。在相同训练 / 验证划分、C＝4、min_df＝2、特征上限20万下，字符1—3 gram验证Macro-F1为88.37%，词1—2 gram为87.20%，相差1.17个百分点；特征维度分别为130996、55013。字符2—5 gram达到20万维却只有87.75%，更大的特征空间未带来更高分。这支持本任务采用字符1—3 gram，也说明表示粒度需要用验证结果选择。案例6957中传统基线仍把其他酒店的推荐错归给当前酒店，提示局部片段对目标关联的表达存在局限；目前没有特征贡献或干预实验，不把该线索说成已经证明的内部机制。详见第⑤、⑥节。

原理二：提示、SFT与LoRA改变模型的方式不同（第13—14讲）。 零样本和少样本不更新权重；少样本通过输入上下文展示标签与格式。SFT利用标注答案的监督损失更新参数，LoRA则冻结基座，将更新限制为低秩矩阵（公式见4.5）。本项目同一Qwen3-1.7B基座的零 / 四样本 / LoRA测试Macro-F1为62.56% / 76.10% / 91.12%，非法率为20.33% / 0.26% / 0。四条示例提高13.55个百分点并大幅减少格式错误；LoRA进一步提高15.01个百分点，说明额外监督适配的收益已超出剩余2条格式错误。相同可训练参数3211264下，T01覆盖q/k/v/o的验证F1为91.39%，高于仅q/v、r16的91.05%，说明更新位置也影响适配效果。三种提示的具体格式及监督量并不完全相同，因此比较完整方案；多对象案例6865表明微调仍有适用边界。

原理三：类别不均衡与非法生成决定评测口径（第14—15讲）。 Accuracy按全部样本等权，Macro-F1先分别计算正负两类F1再等权平均，少数类不会被多数类数量直接淹没。训练集多数类为正面；固定全部预测正面，在测试集532正 / 245负上得到Accuracy＝532/777＝68.47%，但负面召回为0，Macro-F1仅40.64%。固定四样本的负面召回虽达96.73%，却把172条正面判成负面，负面精确率仅57.95%，Macro-F1为76.10%；只看单类召回会得出片面结论。零样本158条非法输出保留在777条分母中，并对真实类别计漏判，否则会掩盖格式失败。由此统一采用验证Macro-F1选优，辅以Accuracy、分类别P/R/F1、非法率与混淆矩阵，测试不参与选参。指标公式及逐运行汇总见5.1—5.4。

上述三点均对应已运行数据。MacBERT的MLM方向与Qwen的AR方向仅作为模型背景；项目未执行预训练目标受控实验、PPL或词向量 / 句向量对照，不将这些概念列作已经完成的原理验证。

③ 系统设计

3.1 总体架构与数据流

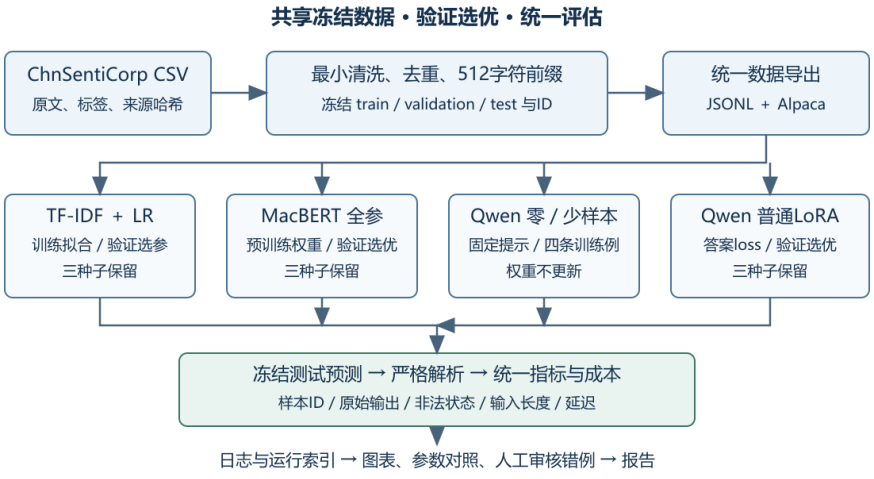


图3-1 数据清洗与划分仅在冻结前完成；模型训练、验证选优与最终测试分别组织。权重保留在个人工具目录，统一项目保存配置、资源关联、预测和证据。

原始CSV经最小清洗和去重，形成共享JSONL与LoRA所需Alpaca格式。训练集用于拟合特征、模型训练和少样本示例选择；验证集用于选配置和检查点；冻结后对测试集预测。各路线输出同一协议的逐样本记录，交由统一评估入口计算指标和错例，再生成图表与报告素材。

3.2 模块与职责

模块	具体负责人	主要交付
冻结数据与跨路线对齐	刘广徽统筹，三人核对各自输入	统一ID、标签、划分、模型输入与哈希
TF-IDF、MacBERT	杨函齐	验证参数对照、三种子、日志与检查点
零样本、四样本	李嘉谊林	固定提示与示例、原始生成与配置
LoRA、融合与分析	刘广徽	参数训练、CLI、指标、九例及图表

预测记录包含样本ID、真值、原始输出、解析标签、状态、输入字符和token长度、截断标记及耗时。新运行使用唯一ID和全新目录；失败、重试和历史结果分别保留。

④ 实现细节

4.1 数据处理与冻结

使用ModelScope AiNiklaus/ChnSentiCorp中的酒店评论CSV，共7766条。只统一换行符、去首尾空白，保留否定词、标点及原始文本；先核查全文重复，再生成前512个Unicode字符的共享正文。排除1条空文本和2条重复截断前缀，得到7763条有效记录，最终203条需要字符截断。前缀碰撞按已确认规则保留源序号最小记录。

划分	数量	负面0	正面1
训练	6210	1954	4256
验证	776	244	532
测试	777	245	532

本项目以该CSV重新分层划分：先取20%临时集，再将其等分为验证与测试，两次种子均67。划分并非原论文的9600/1200/1200设置。冻结后ID集合互斥、精确重复前缀无跨集碰撞；未实施近似语义去重。成员来源数据的Alpaca正文哈希和ID顺序已对齐，通用JSONL序列化差异及未能逐字核对的历史部分保留在审计中。

JSONL保留原文、规范化正文、源序号及标签；Alpaca映射任务说明、正文与数字答案。数量守恒7766＝7763＋1空文本＋2前缀碰撞；稳定ID按源文件SHA256与source_row组成。各冻结文件及少样本 / 延迟 / 冒烟子集均有哈希。

模型输入还要经过token预算检查。MacBERT在512 token内保留特殊符号；Qwen预算包含任务说明、聊天模板和少样本示例。超限时只缩短目标评论，不截掉任务说明或示例。字符截断与token截断使用不同字段记录，使后续能核查模型实际看到了什么。

4.2 最终训练与推理配置

路线	实际配置
TF-IDF＋LR	字符1—3 gram，min_df=2，最多20万特征，sublinear TF；LR的C=4，lbfgs，max_iter=2000，不加类别权重；仅在训练集拟合
MacBERT	hfl/chinese-macbert-base预训练全参；token上限512，batch8，累积1，最多3轮；AdamW，lr2e-5，weight_decay0.01，warmup0.1，linear，裁剪1.0，FP32
Qwen零 / 少样本	Qwen/Qwen3-1.7B，总输入上限2048 token，BF16，关闭思考，贪心、单束、最多8个新token；超限仅从评论尾部截断
普通LoRA T01	同Qwen基座，r8、alpha16、q/k/v/o、dropout0.05；3轮，lr1e-4，AdamW，weight_decay0，warmup0.1，linear；microbatch1、累积16，BF16、梯度检查点，仅答案token计算loss

MacBERT共有102269186个可训练参数，LoRA T01为3211264个。模型revision及SHA256见附录A。

零 / 少样本使用“判断评论整体情感，仅输出0表示负面、1表示正面”的任务说明。四条示例来自训练集，按负、正、负、正固定；LoRA推理不放示例。模板、示例ID和模型版本见附录A。

4.3 传统基线：从特征构建到可重载Pipeline

TF-IDF与逻辑回归封装在同一Pipeline中，先在训练集拟合字符片段词表和逆文档频率，再对验证/测试文本执行转换。由此固定“哪些数据可以更新特征统计”的边界。实际使用次线性词频和带平滑的逆文档频率，对出现过的片段t，其未归一化权重可写为：

$$w(t,d) = (1 + \ln f(t,d)) \times [\ln((1 + N_{训练}) / (1 + df(t))) + 1], \quad f(t,d) > 0$$

其中，$f_{t,d}$为片段t在评论d中的出现次数，df_t为含该片段的训练评论数；未出现片段权重为0，向量随后进行L2归一化。逻辑回归依据稀疏特征预测类别，四组特征配置均保存拟合时间、特征维度、迭代次数、警告和训练/验证log-loss。

字符1—3 gram、种子42的实际记录为：特征130996维，优化36次迭代，拟合6.0282秒，训练log-loss为0.143556、验证log-loss为0.275940，验证Macro-F1为0.883748。保存Pipeline后重载并核对预测，三个种子的最终结果全部保留。逻辑回归只保存实际最终值，不伪造训练逐步曲线。

4.4 MacBERT：全参训练、逐轮选优与恢复检查

加载预训练编码器后，分类头将池化表示映射为两类概率：

$$p(x) = \mathrm{softmax}(W_c \cdot h_{pool}(x) + b_c), \quad 预测标签 = \arg\max p(c \mid x)$$

使用分类交叉熵训练，编码器、嵌入层和分类头全部参与梯度更新。每个batch保存步数、轮次、loss、当前学习率和实测batch耗时；每轮保存验证预测及指标，并按验证Macro-F1更新最佳检查点。训练与测试入口分离，队列完成后才衔接冻结配置的测试。

以下两行逐字摘自bert-len512-seed42/train_steps.jsonl，seconds为该batch记录区间耗时，不是从启动到结束的完整时间：

{"step": 1, "epoch": 1, "loss": 0.7207541465759277, "lr": 8.583690987124465e-08, "seconds": 0.2948879670000224}

{"step": 2, "epoch": 1, "loss": 0.740314245223999, "lr": 1.716738197424893e-07, "seconds": 0.16876767700000528}

种子42三轮训练loss为0.344469 / 0.215189 / 0.115225，验证Macro-F1为88.5968% / 90.8144% / 90.8733%，选第3轮。保存模型、优化器、调度器与随机状态；已检查epoch边界恢复。8组搜索加2次补种子均有逐步/逐轮证据。完整表见附录B。

4.5 LoRA：答案掩码、参数注入与有效批量

对选定投影矩阵，LoRA将参数更新写为：

$$W = W_0 + \Delta W = W_0 + (\alpha / r)\, BA$$

其中W_0为冻结基座权重，A和B为可训练低秩矩阵，r为秩；本项目最终r＝8、alpha＝16。训练输入包含任务说明与评论，只有答案位置集合A参与自回归损失：

$$L_{答案} = -(1 / |A|) \sum_{t \in A} \ln p_\theta(y_t \mid x, y_{<t})$$

任务说明和评论位置不计算监督loss，避免把复述输入当成训练目标。BF16、梯度检查点与梯度累积配合使用；单卡有效批量为：

$$B_{有效} = B_{微批量} \times K_{累积} \times G_{设备数} = 1 \times 16 \times 1 = 16$$

LLaMA-Factory配置记录train_on_prompt=false、gradient_checkpointing=true、overwrite_output_dir=false，每10步记录日志，每轮保存后以生成标签的验证Macro-F1选检查点。以下为T01原始Trainer日志的前两条：

{"current_steps": 10, "total_steps": 1167, "loss": 5.128038787841797, "lr": 7.692307692307694e-06, "epoch": 0.02576489533011272, "percentage": 0.86, "elapsed_time": "0:00:31", "remaining_time": "1:00:35"}

{"current_steps": 20, "total_steps": 1167, "loss": 4.390075302124023, "lr": 1.623931623931624e-05, "epoch": 0.05152979066022544, "percentage": 1.71, "elapsed_time": "0:00:59", "remaining_time": "0:56:35"}

loss为日志窗口统计；T01种子42第1/2/3轮验证Macro-F1依次为90.4138%、90.8723%、91.3885%，最佳为第3轮checkpoint-1167。训练配置、trainer_log.jsonl、trainer_state.json、逐轮验证与best_checkpoint.json相互关联。10组搜索和T01补种子43、44共12个成功运行的日志保留；中途失败批次另存，不覆盖。来源见T01原配置、逐轮验证。

4.6 提示恢复、统一接口与证据链

零 / 少样本负责人提供的历史包包含提示注册表及示例ID，但部分示例正文脱敏。融合时按四条训练ID恢复正文，核查标签、文本哈希和聊天模板哈希，再复核两种提示共1552条历史验证输入的渲染哈希。正式评估不凭手工复制的几段提示替代历史配置。

工程入口将不同来源转成统一协议，训练、预测、评估分别组织。每条预测保存sample_id、true_label、raw_output、parsed_label、status、长度、截断、token数与耗时；运行索引保存模型、检查点、配置、种子、源产物哈希和正式 / 冒烟阶段。严格解析核心逻辑为：

```
def parse(raw):
return int(raw.strip()) if isinstance(raw, str) and raw.strip() in ("0", "1") else None
```

上段与实际函数逻辑一致；评估还检查样本数量、ID顺序、重复ID、真值、划分、原始输出与解析状态是否一致。格式非法是一次完整预测中的任务失败；OOM、超时、漏预测等基础设施失败则阻止发布完整主成绩。两种情况不合并处理，修复重跑使用新ID。

可核查工作	已保存证据与检查范围
三方代码接入	传统基线、MacBERT、提示与LoRA统一到src/cli.py；原代码归档保留
基线审计	10次BERT、6次TF-IDF，最佳轮次、模型 / Pipeline哈希和重载预测
正式预测对齐	16份验证 / 测试记录，11份最终测试每份777条；统一重算指标
正式推理计时	11份同200条延迟记录，固定20条训练评论预热，GPU计时同步
训练过程追溯	补取54份既有训练日志 / 配置证据并校验；BERT和LoRA分图
软件检查	早期正式比较日志30项、后续演示49项；项目核查时完整软件检查56项通过，验证工程行为，不代替模型效果评价

由此形成“源数据与配置→模型 / 适配器→逐样本预测→统一指标→图表→报告结论”的关联链。具体代码见提示适配、严格评估，已有软件检查记录见30项检查日志。运行记录覆盖训练、预测、指标重算与交付核查。

4.7 关键问题与解决记录

实际问题	处理方式与验证
原基线包按Accuracy选优，缺少可核查的各轮验证产物	统一改为验证Macro-F1；重新执行8组BERT与4组TF-IDF搜索，保存每轮指标、配置、模型和验证预测
冒烟前32条仅含正类，逻辑回归拟合失败	保留原失败状态，改用两类各16条的冒烟子集重试；不计入正式成绩
首次预热ID查询划分错误	按全部冻结划分查找原ID，不重新抽样或改变预热ID
首次TF-IDF延迟与BERT训练重叠	原记录留档；正式采用后续独立test-isolated测量
提示来源包示例正文被脱敏	按固定训练ID恢复，并核验示例文本及历史验证输入哈希
不同路线输出与指标不一致	统一严格0/1解析、非法计错、完整ID校验及独立重算；首次失败与重试关联记录

模型保存后重载核查预测；BERT验证了epoch边界模型、优化器、调度器和随机状态恢复。未将这一检查扩大描述为任意step精确恢复或所有路线完整续训。

4.8 环境

硬件为Intel Core i7-14650HX（16核24线程）、16GiB内存、RTX 4070 Laptop GPU（8188MiB显存）。模型运行于Windows宿主下WSL2 Ubuntu22.04.5，Python3.11.17、PyTorch2.14.1、Transformers5.8.0、PEFT0.18.1、scikit-learn1.9.1、LLaMA-Factory0.9.6.dev0。MacBERT使用FP32，Qwen使用BF16，模型推理在本机完成，没有按token付费的模型API调用。

环境标识E01：硬件与驱动于2026-10-29补采，训练与推理使用同一硬件和基础环境，配置已经确认。驱动616.92，驱动报告CUDA支持13.4，PyTorch CUDA构建13.0；独立Toolkit版本未确认。离线统计绘图为Windows Python3.13.9、NumPy2.3.5，单独记录。完整来源见环境说明。

⑤ 评估

主表来自777条测试预测；验证只用于选优，成本延迟集中第⑦节。完整公式、分类别结果与口径见附录C。

5.1 数据、指标与汇总口径

测试集777条，负面245条、正面532条，数据来源与划分见4.1。以整条评论为评价单位。对类别c∈{0,1}，TP_c表示真实与预测均为c的条数，FP_c表示其他类别被预测为c的条数，FN_c表示真实为c却未正确识别的条数。精确率关注“判为该类的有多少正确”，召回率关注“该类实际样本中找回多少”：

$$\text{精确率 } P_c = TP_c / (TP_c + FP_c)$$

$$\text{召回率 } R_c = TP_c / (TP_c + FN_c)$$

$$\text{类别 } F1_c = 2P_cR_c / (P_c + R_c) = 2TP_c / (2TP_c + FP_c + FN_c)$$

宏平均F1＝(负面F1＋正面F1)/2；Accuracy＝正确条数/N；加权F1按真实类别数量加权；非法率＝非法输出条数/N。

分母为零时相应值记0。Qwen输出仅去首尾空白，完整等于0或1才合法；非法输出仍计入N，对真实类别形成漏判，不从测试集中删除，也不取首数字重新评分。混淆矩阵保留“预测负面、预测正面、非法”三列。基础设施失败导致预测不完整时，不发布完整主指标。

验证Macro-F1选优，Accuracy及加权F1为辅助。

训练种子42、43、44，每种子先独立计算指标，再求均值和样本SD；提示为确定性单次。划分、抽样与bootstrap种子67。已查看测试，改进不得覆盖冻结结果。

5.2 主结果：MacBERT与LoRA领先，跨机差异集中于Qwen

方案	宏平均F1	准确率	加权F1	非法率
多数类参考：全部正面	40.64 / 40.64	68.47 / 68.47	55.65 / 55.65	0.00 / 0.00
TF-IDF＋逻辑回归	86.10 / 86.10	88.42 / 88.42	88.20 / 88.20	0.00 / 0.00
MacBERT全参微调	91.52 / 91.52	92.62 / 92.62	92.65 / 92.65	0.00 / 0.00
Qwen零样本	62.56 / 64.38	59.59 / 61.65	66.16 / 67.84	20.33 / 18.79
Qwen固定四样本	76.10 / 75.93	76.58 / 76.45	77.44 / 77.28	0.26 / 0.13
Qwen普通LoRA	91.12 / 90.93	92.28 / 92.11	92.30 / 92.13	0.00 / 0.00

表1 两机完整测试主结果，单元格均为“4070 / 4060”，单位%。各机使用同一777条测试集、权重、提示与锁定依赖；训练路线各3种子取均值，零 / 四样本各1次。多数类为共同参考。两机结果分别保留，不混合求均值；更精确的F1及差异见表1b。

两机效果排序一致。MacBERT与TF-IDF逐样本一致；Qwen零样本F1跨机差1.821个百分点，四样本与LoRA为0.178、0.191。LoRA相对四样本在两机均提高约15个百分点。硬件相关数值变化作为主结果解释的一部分。

跨机复验结果进入主表解释：

方案	4070 / 4060 F1（%）	差值（百分点）	输出差异数
TF-IDF	86.104 / 86.104	+0.000	0
MacBERT	91.518 / 91.518	+0.000	0
Qwen零样本	62.559 / 64.380	+1.821	72
Qwen四样本	76.105 / 75.927	-0.178	7
Qwen LoRA	91.116 / 90.925	-0.191	6

表1b 原4070结果与4060完整复验。差异按“运行×样本”计数，TF-IDF、MacBERT及LoRA各含3个种子，其余各1次；两机均为11次×777条。85条输出差异中61条改变解析标签。成本仍采用环境E01，不混合两机成绩。

零样本跨机波动明显；四样本、LoRA幅度较小。BF16数值诊断见第⑥节及附录G，不能只以版本号相同认定结果一致。

5.3 分类别表现与非法生成：高负面召回不等于整体最好

TF-IDF负面召回75.51%，四样本负面召回96.73%却误判172条正面；MacBERT与LoRA两类较均衡。零样本158条非法，四样本2条，LoRA均0；原分类别完整指标见报告源文档。多数类参考Accuracy68.47%但负面召回0，说明只看Accuracy不足。

5.4 三种子稳定性及MacBERT与LoRA的差距

本节种子与bootstrap采用4070原始预测；4060中MacBERT领先LoRA为0.593个百分点，原约70%比例不外推为跨硬件概率。

方案	种子42	种子43	种子44	均值	SD / 百分点
TF-IDF＋逻辑回归	86.10%	86.10%	86.10%	86.10%	0.000
MacBERT全参微调	91.65%	91.12%	91.78%	91.52%	0.346
Qwen普通LoRA	91.27%	90.98%	91.10%	91.12%	0.149

表3 每个训练种子的测试Macro-F1及汇总。SD以百分点表示；提示不重复相同确定性运行充当独立随机实验。

MacBERT平均比LoRA高0.40个百分点，LoRA三次训练的SD为0.149个百分点，小于MacBERT的0.346个百分点，观察到的分数波动更小。案例7015中只有MacBERT种子44误判，说明总体均值之外仍需保留样本级差异。

简化配对分层贝叶斯bootstrap采用种子67，在10000次中6991次MacBERT均分更高，即约70%；另一个配对bootstrap差值95%区间为□1.07至1.93个百分点。MacBERT略领先但效果接近。方法及原预测哈希见附录C。

5.5 路线内参数对照与最终配置

本节全部使用验证集776条、种子42，不混用测试成绩。先给出三条训练路线的代表对照，再汇总其余参数证据。

TF-IDF固定C＝4、min_df＝2、20万特征上限；char_2_4 / char_1_3 / char_2_5 / word_1_2验证F1为88.09% / 88.37% / 87.75% / 87.20%，选char_1_3。完整特征维度见2.3及附录C。

MacBERT学习率与长度配置。 在长度256、batch16、最多3轮时，学习率1e-5 / 2e-5 / 5e-5的验证Macro-F1为90.47% / 90.62% / 90.49%，2e-5稍优。沿用该学习率比较长度与批量：

MacBERT长度128 / 256 / 512对应batch16 / 16 / 8，验证F1为89.42% / 90.62% / 90.87%，最终选512。此为长度与batch组合对照；时间开销归第⑦节。

LoRA秩与注入模块。 保持alpha/r＝2：

配置	注入模块	r / alpha	可训练参数	验证Macro-F1
B00	q/v	8 / 16	1605632	90.95%
R01	q/v	16 / 32	3211264	91.05%
T01	q/k/v/o	8 / 16	3211264	91.39%

q/v秩翻倍，可训练参数翻倍，F1仅提高0.10个百分点。T01与R01可训练参数相同，扩大模块覆盖比只增大q/v秩高0.34个百分点，因此选择T01补种子43、44。其余学习率、类别权重、轮数、部分冻结、warmup、衰减与dropout共十二项已确认结论保留附录C；不把未运行组合的收益相加。

5.6 训练曲线与检查点：loss下降不等于验证持续改善

MacBERT种子42的loss从0.344469降至0.115225，验证F1从88.5968%升至90.8733%；LoRA验证F1从90.4138%升至91.3885%。真实训练曲线见附录D。

预算对照中，BERT最多5轮的训练loss从0.3447继续降到0.0298，但验证最佳在第1轮，后续没有持续提高。训练loss衡量训练样本拟合，最终检查点仍按验证F1选择。TF-IDF只记录最终训练 / 验证log-loss和36次优化迭代，不补绘逐步曲线。

BERT分类loss与LoRA答案token loss定义不同，分别展示。BERT按步曲线和累计batch实测时间不等于完整墙钟；LoRA按每10步窗口及Trainer耗时绘制。训练过程图反映真实记录，不以平滑或补点掩盖波动。

5.7 输入长度与截断的检查

共享输入先取前512字符，再检查各模型token预算。测试集中757条不需字符截断、20条需截断；后者样本数小于30，只作描述。长度与token子群还受到类别比例、示例占用和未知字段影响，不将观察到的分组分数差直接解释为截断造成的损失。

这项检查帮助错误分析排除不符合证据的解释。例如案例5546仅38字符、4086仅49字符、6197仅100字符且没有记录到相应截断，不能将这些错误简单归因于评论太长。完整长度分布、token状态和子群数量保留在正式图表总览及对应JSON中。

⑥ 错误分析与局限

6.1 五类失败及改进方向

从11个测试运行取错误并集，得到402条去重评论、1118个错误“样本—运行”组合。人工试标20条，其余382条由AI按确认规则辅助标注；本节九例解释及正文编排经人工逐项审核。正式报告采用这九例作定性分析，不再逐条复核其余124条未纳入人工定稿材料；已有AI归因数量仅保留为探索性附录，不写成人工定稿的分类比例。五组正文共七例，另两例讨论标签和稳定性。全部777条测试评论仍用于正式评分。具体范围见错例与数据使用核查。

类别 / 案例ID尾号	失败样例：输入线索→实际输出	归因与局限	可能的改进
任务适应性 / 5546	“很差，相当差”，真值负面→仅零样本合法输出1；其余路线正确	当前提示下，原始模型仍会误判明确情感；38字符，无记录到的截断	代表性示例或监督适配；本例已被少样本和LoRA修正
混合评价 / 6353、4086	卫生差但肯定前台，负面→TF-IDF三种子判正；弱肯定夹杂缺点，正面→零 / 少样本判负	整体与局部评价取舍会在两个方向失败；6353零样本另属格式错误	核查特征贡献，以正负两方向混合评价验证分句或方面特征
多评价对象 / 6865、6957	当前酒店差、另一酒店更好，负面→6957仅TF-IDF三种子判正；6865多个监督模型仍判正	不同酒店、平台和方面的情感归属可能混淆	明确目标对象并验证边界标记，同时检查单对象样本退化
多说话者 / 6197	住客批评后附酒店回复，负面→TF-IDF、MacBERT、LoRA三种子及少样本共10次判正	回复与住客立场不同；也可能受开头肯定影响	对照原文、角色标记、仅住客正文，核查实际收益
格式遵循 / 5773	扣房费、不满意，负面→零样本输出“根据评论内容，整体情感偏向负面。”	语义表达负面但不满足数字协议，正式计非法；其余运行正确	验证限定0/1完整序列的解码约束，联合检查分类、非法率和延迟

多对象主例6865中，MacBERT42/44、TF-IDF及LoRA三个种子均判正，MacBERT43和少样本判负；零样本输出1后解释，正式为非法。该例说明微调后仍存在复杂比较错误。固定少样本在4086也未修正弱正面误判，因此案例5546的改善不外推为“少样本或微调消除所有错误”。

6.2 数据、稳定性及覆盖局限

案例647源标签正面而人工初判负面，涉及陈旧设施、卫生间、服务和早餐的不同取舍，存在标签理解分歧，正式分数保留源标签。案例7015为明确负面，只有MacBERT种子44判正，其他运行均正确，说明逐样本结果可能随训练运行变化。

124条未纳入人工定稿的探索性材料包括73条标签分歧、45条不确定、6条输入可见性问题。全部402条不能表述为独立人工金标；对象或说话者混淆是证据支持的解释线索，尚未通过输入干预验证机制。改进建议利用了测试反馈，未来需单独编号评估，不覆盖冻结结果。

数据集中于酒店领域，不能直接推定电商、社交文本等领域表现。512字符前缀及模型token预算可能丢失尾部线索，测试字符截断子群仅20条，不据此作强因果排名。搜索主要为单种子、有限候选，未覆盖所有参数组合。不同基座、结构、精度、提示和监督量意味着本项目比较完整方案，不能把全部差异归因于某个训练机制。九例全文及逐运行输出见确认版案例。

6.3 BF16与跨机稳定性

正式Qwen为BF16，不是FP16；MacBERT为FP32。两机全部输入和权重已校验。验证诊断16条输入token与buffer一致，原路径首步得分指纹16条不同、1条首token分歧；4060同机两轮所有逐步得分一致。受控Flash / Math仍各有1条输出不同，说明首步数值排序影响贪心生成，但具体内核与FP32改善效果尚未证实。小样本解释全量复验中的数值差异，详见附录G。

⑦ 工程与伦理

7.1 推理延迟、吞吐与token用量

同一200条测试评论、固定顺序，使用20条训练评论预热，模型提前加载，batch1串行、线程配置4；计时包含分词、设备传输、推理和解析，排除读盘与模型加载，GPU前后同步。对单次运行，平均延迟和串行吞吐为：

$$\text{平均延迟} = \Sigma t_i / n；\text{串行吞吐} = n / (\Sigma t_i / 1000)\ \text{条/秒}，n = 200$$

P50 / P95由该运行的200条延迟计算，分位方法为linear；训练路线再对三个运行摘要取平均，不将“P95均值”写成合并样本P95。吞吐也先逐运行计算再平均。

方案	设备	平均延迟ms	P50均值ms	P95均值ms	平均吞吐条 / 秒
TF-IDF＋逻辑回归	CPU	0.555	0.507	0.894	1803.122
MacBERT全参微调	GPU	6.133	5.102	10.668	163.859
Qwen零样本	GPU	97.706	61.873	251.918	10.235
Qwen固定四样本	GPU	79.414	75.232	100.536	12.592
Qwen普通LoRA	GPU	59.056	57.647	70.277	16.969

表4 本机端到端延迟，单位ms，吞吐为条 / 秒。TF-IDF为CPU，MacBERT为GPU FP32，Qwen为GPU BF16；环境E01。

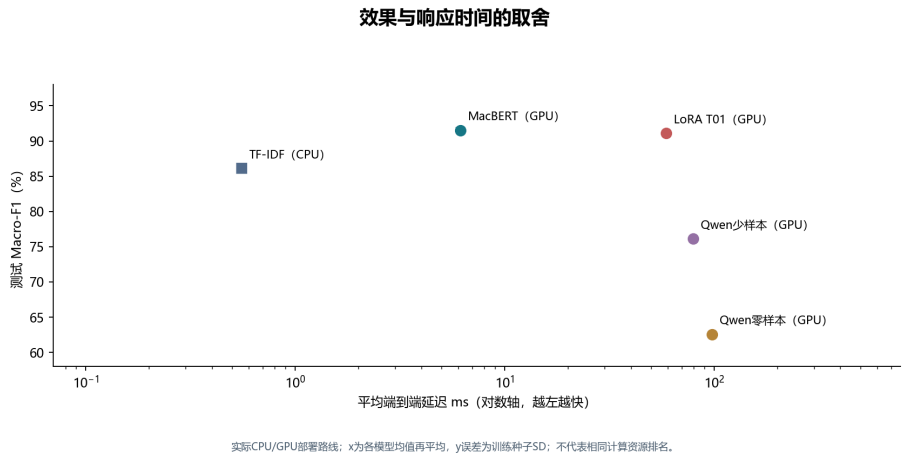


图7-1 效果—延迟取舍，图内尺度和误差条含义按原图注读取；执行位置与精度如表4。

TF-IDF平均约0.56ms，适合低延迟轻量部署。MacBERT以6.13ms取得91.52%的Macro-F1；LoRA约59.06ms，为MacBERT的9.6倍，但低于原始Qwen零 / 少样本。Qwen序列生成与MacBERT单次分类不同，输出长度也是完整方案延迟的一部分。

方案	平均输入token	平均输出token
Qwen零样本	111.23	3.22
Qwen固定四样本	380.23	2.02
Qwen普通LoRA	104.84	2.00

表5 各运行777条测试预测的平均输入 / 输出token，非200条计时子集统计；输出长度沿用原记录，可能包含终止标记。LoRA三种子均值相同。

四条示例增加输入长度，少样本平均输入380.23 token，而零样本111.23；零样本平均输出3.22 token，多于少样本的2.02。因而不能仅依据输入更长，就认定少样本端到端延迟必然更高。分类模型均为本地运行，token用量不换算API账单。用量核查

7.2 训练实验投入与部署资源

路线	搜索运行数	补种子运行数	已记录成功运行累计时长
TF-IDF	4	2	1.73分钟
MacBERT	8	2	37.85分钟
LoRA	10	2	约10小时21分钟

表6 按成功运行身份去重，种子42已计入搜索，只额外计算43 / 44。各路线历史时间边界不同，失败及准备工时未知，累计值为已记录成本下界。

按已记录成功运行墙钟折合：CPU路线TF-IDF约0.0288小时、GPU路线MacBERT约0.6308小时、LoRA约10.3474小时；这些是运行区间的设备占用时长，非利用率或功率积分，不代表完整人工工时。

三条训练路线共保留28次成功正式训练 / 拟合（TF-IDF 6次、MacBERT 10次、LoRA 12次），冒烟、失败与重试另行记录。

TF-IDF实验迭代投入最低；MacBERT累计37.85分钟取得91.52%的Macro-F1，LoRA累计约10小时21分钟取得91.12%。LoRA T01单次Trainer约59—60分钟，不能把全部搜索当成单模型耗时。结合推理延迟，MacBERT在本项目体现较好的效果与时间成本平衡。

方案	总参数与可训练参数说明	推理allocated / reserved峰值MiB	完整部署
TF-IDF	char_1_3的LR系数及截距共130997个，另需词表与IDF	不适用	5.96MB
MacBERT	总参数102269186，全部可训练	416.88 / 470	409.54MB
Qwen零样本	基座1720574976，任务训练更新0个	3365.10 / 3404	4.08GB
Qwen少样本	同基座，任务训练更新0个	3409.08 / 3504	4.08GB
Qwen LoRA T01	基座加3211264个可训练增量参数，约占含适配器模型的0.19%	3372.59 / 5202	4.09GB

表7 参数数量与部署资源。TF-IDF的系数数量不是与神经网络等价的容量衡量；显存取各运行记录峰值中的最大值，不是均值。

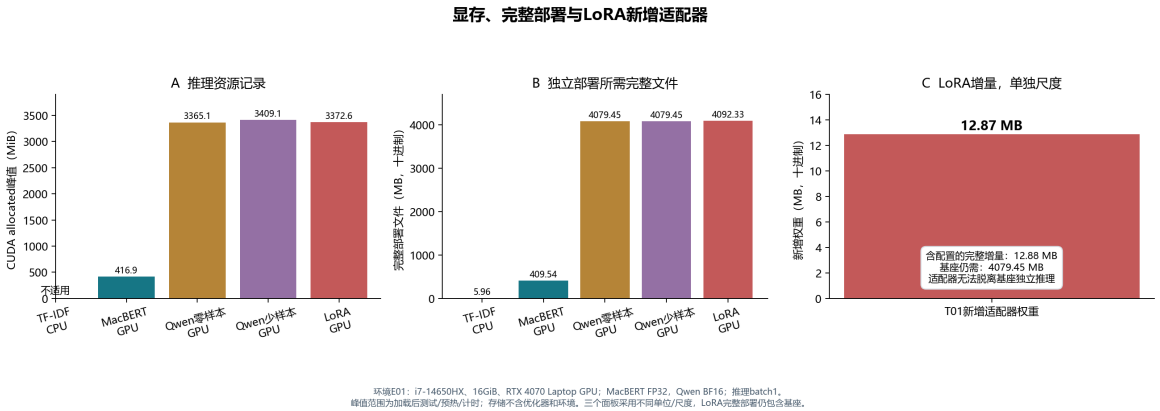


图7-2 allocated显存、完整部署和新增适配器三个面板。环境E01；MB/GB为十进制，MiB为二进制。图中显存涵盖加载后的测试、预热和计时，不当作训练峰值。

LoRA新增权重12.87464MB，含配置增量12.875648MB，便于任务增量保存和分发；独立部署仍需约4079.45MB基座，总体4092.33MB。allocated与reserved不相加，结束RSS不冒充峰值内存。部署大小不包含Python环境或优化器状态。由此可见，适配器小与完整运行轻量是不同的成本指标。

具体参数的耗时对照、适配器大小与原始LoRA图E1见附录E；正文第⑤节只保留效果及配置对照。

7.3 效果与成本的综合结论

在冻结酒店评论测试集与环境E01中，MacBERT以91.52%的Macro-F1、6.13ms平均GPU延迟和409.54MB完整部署，兼顾效果与响应速度；LoRA达到91.12%，相比固定少样本提高15.01个百分点，并以12.87MB适配器保存任务更新，但完整部署约4.09GB、平均延迟59.06ms。TF-IDF以86.10%的Macro-F1、约0.56ms CPU延迟和5.96MB产物提供轻量参照。

MacBERT原论文的中文分类结果仅作研究背景；不同划分、指标和基座不能支持把全部优势归因于某一预训练机制。

两机排名一致。MacBERT与TF-IDF逐样本一致，零样本波动较明显，四样本与LoRA较小。成本仅适用于E01，跨机数值稳定性也应纳入方案选择。

7.4 资源获取、复现与演示

课程ZIP随附源码、README与文件SHA256清单；历史发布版见课程提交版Release。本次修订以所交压缩包内的版本及文件身份为准，数据、权重和视频继续通过链接获取。

源码随同一ZIP交付；数据、预测及日志按固定Git提交链接下载并验SHA256；9份训练产物见GitHub Release，Qwen基座另取。包内一条命令python src/run.py重算已有预测，4070独立环境复现逐样本一致；4060已完整完成11次预测，85条跨机输出差异作为硬件稳定性实验结果报告。视频111.317秒，网盘访问已人工确认；链接及提取码见首页，录屏不入ZIP。详见附录F。

完整模型复现已验证于WSL2 / Python3.11.17 / torch2.14.1+cu130及冻结依赖，RTX4070 Laptop 8GB、宿主机16GiB；BERT GPU FP32、Qwen GPU BF16。此为实测配置，非已证明的最低配置。CPU可核查既有主表，不能据此声称完成模型重预测。其他PyTorch / CUDA组合未通过一致性验证，不列为正式环境。

复现先核查11次各777条完整性及资源身份：TF-IDF、MacBERT与两机一致结果核对；Qwen以两机实测成绩和差异为基准，不要求不同硬件逐token相同。原精确对照脚本仍可能返回1并记录completed_with_differences，表示输出有差异而非程序未完成；安装与运行命令不变。

7.5 许可、权限与隐私

ModelScope数据卡标记Apache 2.0，源CSV与上游哈希一致；评论独立再分发授权链未核实。沿用公开数据原样使用方案，不额外脱敏；7763条规则扫描有9条、11处联系方式候选，不能声称全库无个人信息。提交ZIP不放数据、权重、视频、密钥或个人环境。LoRA的SwanLab为cloud模式，本地三个备份7638条记录包括指标、配置、环境和终端日志；所查正文与联系方式未匹配，远程账号未全面核查。检查范围见附录E。

7.6 AI使用声明与人工核查

Codex等AI用于文档查阅、参数候选和方案整理、工程编写调试、接口与指标核查、图表、382条错例辅助标注及文字组织；精确模型版本未确认。刘广徽选择确认方案、试标20条、逐例审核九案例、确认八项模型及十二项参数结论，并修改任务适应性解释。核查采用原始输出、配置哈希、日志和独立指标重算；其余124条不作人工定稿统计。Codex的具体使用环节、人工修改和核查方法见附录E。AI参与工程及文字整理，实验选择和结果判断由项目成员负责。完整声明见附录E。

⑧ 分工与贡献

三人分别投入40 / 20 / 15小时，综合贡献为40% / 30% / 30%。各路线负责人负责输入适配、配置对照、执行与日志；统一保持冻结划分、ID和标签。

学号 / 姓名	负责的具体工作	对应产出证据	工时 / 贡献
20245726 刘广徽（组长）	技术选型与任务分析、初步方案；LoRA数据适配、10组参数训练及T01补种子；融合CLI和统一评估；对比、九例审核、报告、演示与提交统筹	src/legacy/lora/、configs/methods/lora-frozen.json、results/qwen17-comparisons/；src/cli.py、src/evaluation/；reports/analysis/case-confirmed-20261029-01/、conclusions-confirmed-20261029-01/及本报告	40h / 40%
20246005 杨函齐	TF-IDF及MacBERT输入适配；4组特征 / 8组全参训练配置对照；各自三种子训练 / 拟合、检查点与日志、验证 / 测试结果交付	src/legacy/baselines/、results/bert-tfidf-20261028-140359/；results/evidence/formal-analysis-20261028-01/bert/、tfidf/及对应预测	20h / 30%
20245816 李嘉谊林	零 / 少样本输入适配；任务提示、固定示例与模板核查；验证 / 测试批量推理、原始输出、解析状态及日志交付	src/legacy/prompt/、configs/methods/prompt_registry.json、few_shot_examples.json；零 / 少样本验证及测试的results/predictions/与运行索引	15h / 30%

刘广徽负责冻结规则与路线融合，落实普通LoRA十组搜索、T01三种子、统一评估及九例解释；杨函齐负责四组TF-IDF和八组MacBERT参数对照、各路线三种子及训练证据；李嘉谊林负责固定零 / 四样本提示、示例与模板身份核查，以及验证和测试的原始生成记录。三项职责分别对应训练配置、逐样本预测、运行日志和结论证据。

人工投入合计75小时，综合贡献结合职责和产出评价，不等同于工时占比。三份独立声明列明模块、证据、工时、AI辅助及队友贡献；与本表一致。

附录A 模型版本、提示模板与输入预算

4.2 最终训练与推理配置

路线	实际配置
TF-IDF+LR	字符1—3 gram，min_df=2，最多20万特征，sublinear TF；LR的C=4，lbfgs，max_iter=2000，不加类别权重；仅在训练集拟合
MacBERT	hfl/chinese-macbert-base预训练全参；token上限512，batch8，累积1，最多3轮；AdamW，lr2e-5，weight_decay0.01，warmup0.1，linear，裁剪1.0，FP32
Qwen零 / 少样本	Qwen/Qwen3-1.7B，总输入上限2048 token，BF16，关闭思考，贪心、单束、最多8个新token；超限仅从评论尾部截断
普通LoRA T01	同Qwen基座，r8、alpha16、q/k/v/o、dropout0.05；3轮，lr1e-4，AdamW，weight_decay0，warmup0.1，linear；microbatch1、累积16，BF16、梯度检查点，仅答案token计算loss

MacBERT共有102269186个可训练参数；LoRA最终T01为3211264个可训练参数。MacBERT基座锁定revision a986e004d2a7f2a1c2f5a3edef4e20604a974ed1。Qwen提示注册表记录revision 4855588ea1a12789f2e965e5f52a9e4a24c94b2a；LoRA原始下载revision未确认，统一评估实际按本地基座文件SHA256锁定，不将注册表字段当成全部历史下载证据。

零样本任务提示为：

```
判断评论整体情感，仅输出0表示负面、1表示正面。
<评论>
{{comment}}
</评论>
```

少样本在同一聊天模板中加入训练集正负各两条，按负、正、负、正排列；固定ID尾号5542、3812、5693、4407，正文可由冻结训练集恢复。LoRA训练与推理不放示例，采用“同一任务说明+单换行+评论”。不同路线的格式如实保留，未在测试后改写成相同提示。配置证据见提示注册表、LoRA冻结配置及基线配置。

附录B 实现日志与检查点证据

4.3 传统基线：从特征构建到可重载Pipeline

TF-IDF与逻辑回归封装在同一Pipeline中，先在训练集拟合字符片段词表和逆文档频率，再对验证 / 测试文本执行转换。由此固定“哪些数据可以更新特征统计”的边界。实际使用次线性词频和带平滑的逆文档频率，对出现过的片段t，其未归一化权重可写为：

$$w(t,d) = (1 + \ln f(t,d)) \times [\ln((1 + N_{训练}) / (1 + df(t))) + 1], \quad f(t,d) > 0$$

其中，$f_{t,d}$为片段t在评论d中的出现次数，df_t为含该片段的训练评论数；未出现片段权重为0，向量随后进行L2归一化。逻辑回归依据稀疏特征预测类别，四组特征配置均保存拟合时间、特征维度、迭代次数、警告和训练 / 验证log-loss。

字符1—3 gram、种子42的实际记录为：特征130996维，优化36次迭代，拟合6.0282秒，训练log-loss为0.143556、验证log-loss为0.275940，验证Macro-F1为0.883748。保存Pipeline后重载并核对预测，三个种子的最终结果全部保留。逻辑回归只保存实际最终值，不伪造训练逐步曲线。

4.4 MacBERT：全参训练、逐轮选优与恢复检查

加载预训练编码器后，分类头将池化表示映射为两类概率：

$$p(x) = \mathrm{softmax}(W_c \cdot h_{pool}(x) + b_c)，预测标签 = \arg\max p(c \mid x)$$

使用分类交叉熵训练，编码器、嵌入层和分类头全部参与梯度更新。每个batch保存步数、轮次、loss、当前学习率和实测batch耗时；每轮保存验证预测及指标，并按验证Macro-F1更新最佳检查点。训练与测试入口分离，队列

完成后才衔接冻结配置的测试。

以下两行逐字摘自bert-len512-seed42/train_steps.jsonl，seconds为该batch记录区间耗时，不是从启动到结束的完整时间：

{"step": 1, "epoch": 1, "loss": 0.7207541465759277, "lr": 8.583690987124465e-08, "seconds": 0.2948879670000224}

{"step": 2, "epoch": 1, "loss": 0.740314245223999, "lr": 1.716738197424893e-07, "seconds": 0.1687676770000528}

同一次运行的逐轮记录如下，表中耗时来自对应日志，不含全部保存等开销：

轮次	训练loss	验证Macro-F1	训练记录秒数	验证秒数	检查点决定
1	0.344469	88.5968%	83.5057	6.2563	当前最佳
2	0.215189	90.8144%	83.1852	6.3012	更新最佳
3	0.115225	90.8733%	83.0655	6.3806	最终选择

保存内容包含模型、优化器、学习率调度器与随机状态，冒烟检查覆盖epoch边界恢复和保存后重载预测。最终种子43在第1轮达到其验证最佳，因此各运行分别恢复最佳检查点，不统一使用最后一轮。8组搜索加2次补种子共10次正式训练均有配置和逐步 / 逐轮证据。日志来源见原始BERT证据。

4.5 LoRA：答案掩码、参数注入与有效批量

对选定投影矩阵，LoRA将参数更新写为：

$$W = W_0 + \Delta W = W_0 + (\alpha / r)\, BA$$

其中W_0为冻结基座权重，A和B为可训练低秩矩阵，r为秩；本项目最终r＝8、alpha＝16。训练输入包含任务说明与评论，只有答案位置集合A参与自回归损失：

$$L_{答案} = -(1 / |A|) \sum_{[t \in A]} \ln p_\theta(y_t \mid x, y_{<t})$$

任务说明和评论位置不计算监督loss，避免把复述输入当成训练目标。BF16、梯度检查点与梯度累积配合使用；单卡有效批量为：

$$B_{有效} = B_{微批量} \times K_{累积} \times G_{设备数} = 1 \times 16 \times 1 = 16$$

LLaMA-Factory配置记录train_on_prompt=false、gradient_checkpointing=true、overwrite_output_dir=false，每10步记录日志，每轮保存后以生成标签的验证Macro-F1选检查点。以下为T01原始Trainer日志的前两条：

{"current_steps": 10, "total_steps": 1167, "loss": 5.128038787841797, "lr": 7.692307692307694e-06, "epoch": 0.02576489533011272, "percentage": 0.86, "elapsed_time": "0:00:31", "remaining_time": "1:00:35"}

{"current_steps": 20, "total_steps": 1167, "loss": 4.390075302124023, "lr": 1.623931623931624e-05, "epoch": 0.05152979066022544, "percentage": 1.71, "elapsed_time": "0:00:59", "remaining_time": "0:56:35"}

这两条loss是相应日志窗口的统计，不能仅凭前20步判断泛化。T01种子42第1 / 2 / 3轮验证Macro-F1依次为90.4138%、90.8723%、91.3885%，最佳为第3轮checkpoint-1167。训练配置、trainer_log.jsonl、trainer_state.json、逐轮验证与best_checkpoint.json相互关联。10组搜索和T01补种子43、44共12个成功运行的日志保留；中途失败批次另存，不覆盖。来源见T01原配置、逐轮验证。

附录C 完整指标公式与参数证据

5.1 数据、指标与汇总口径

测试集777条，负面245条、正面532条，数据来源与划分见4.1。以整条评论为评价单位。对类别$c \in \{0,1\}$，TP_c表示真实与预测均为c的条数，FP_c表示其他类别被预测为c的条数，FN_c表示真实为c却未正确识别的条数。精确率关注“判为该类的有多少正确”，召回率关注“该类实际样本中找回多少”：

$$精确率\ P_c = TP_c / (TP_c + FP_c)$$

$$召回率\ R_c = TP_c / (TP_c + FN_c)$$

$$类别\ F1_c = 2P_cR_c / (P_c + R_c) = 2TP_c / (2TP_c + FP_c + FN_c)$$

精确率和召回率的调和平均形成类别F1；宏平均对两类等权，加权F1则按真实类别数量n_c加权：

$$\text{Macro-F1} = (\text{F1负面} + \text{F1正面}) / 2$$
$$\text{Weighted-F1} = \Sigma[c=0,1]\ (nc/N)\ F1c$$

准确率和非法输出率分别为：

$$\text{Accuracy} = \text{预测正确的评论条数} / N$$
$$\text{非法输出率} = \text{未严格输出0或1的评论条数} / N$$

分母为零时相应值记0。Qwen输出仅去首尾空白，完整等于0或1才合法；非法输出仍计入N，对真实类别形成漏判，不从测试集中删除，也不取首数字重新评分。混淆矩阵保留“预测负面、预测正面、非法”三列。基础设施失败导致预测不完整时，不发布完整主指标。

选择参数和检查点使用验证Macro-F1；Accuracy与Weighted-F1为辅助，避免多数类掩盖差评漏判。训练方案对三个种子分别计算指标，再求均值与样本标准差：

$$\text{均值 m_mean} = (1/S)\ \Sigma\ m_s$$
$$\text{样本 SD} = \sqrt{[\Sigma\ (m_s - \text{m_mean})^2 / (S - 1)]},\ S = 3$$

训练种子为42、43、44；提示采用确定性单次。数据划分种子67与统计重采样种子67用途不同。下文百分点差均从未舍入值计算。历史测试已被查看，案例及概率分析属于事后解释；后续改进应另立版本。

5.4 三种子稳定性及MacBERT与LoRA的差距

本节种子与bootstrap采用4070原始预测；4060中MacBERT领先LoRA为0.593个百分点，原约70%比例不外推为跨硬件概率。

方案	种子42	种子43	种子44	均值	SD / 百分点
TF-IDF＋逻辑回归	86.10%	86.10%	86.10%	86.10%	0.000
MacBERT全参微调	91.65%	91.12%	91.78%	91.52%	0.346
Qwen普通LoRA	91.27%	90.98%	91.10%	91.12%	0.149

表3 每个训练种子的测试Macro-F1及汇总。SD以百分点表示；提示不重复相同确定性运行充当独立随机实验。

MacBERT平均比LoRA高0.40个百分点，LoRA三次训练的SD为0.149个百分点，小于MacBERT的0.346个百分点，观察到的分数波动更小。案例7015中只有MacBERT种子44误判，说明总体均值之外仍需保留样本级差异。

为回答“有多大把握认为MacBERT更好”，沿用已确认的简化配对分层贝叶斯bootstrap：类别内抽取Dirichlet权重，同一条评论的权重共享给六个已训练模型，分别计算三个种子均分差。种子67、10000次中6991次MacBERT均分更高：

$$P(\text{三种子平均F1：MacBERT} > \text{LoRA}) \approx 6991/10000 = 0.6991 \approx 70\%$$

这一条件概率略偏向MacBERT，两者效果接近。另一个5000次配对bootstrap的差值95%区间为□1.07至1.93个百分点，仍包含0。两项统计描述固定模型与当前样本构成，不把检验p值换成优胜概率。方法与原预测哈希

5.5 路线内参数对照与最终配置

本节全部使用验证集776条、种子42，不混用测试成绩。先给出三条训练路线的代表对照，再汇总其余参数证据。

TF-IDF特征对照。 固定C＝4、min_df＝2、特征上限20万：

特征	验证Macro-F1	特征维度
字符2—4 gram	88.09%	192406
字符1—3 gram	88.37%	130996
字符2—5 gram	87.75%	200000
词1—2 gram	87.20%	55013

字符1—3 gram比词方案高1.17个百分点，选作最终基线。字符2—5达到特征上限，分数却没有提高，说明扩大表示规模不必然改善任务表现。

MacBERT学习率与长度配置。 在长度256、batch16、最多3轮时，学习率1e-5 / 2e-5 / 5e-5的验证Macro-F1为90.47% / 90.62% / 90.49%，2e-5稍优。沿用该学习率比较长度与批量：

token上限	batch	验证Macro-F1
128	16	89.42%
256	16	90.62%
512	8	90.87%

最终选择512配置，相对256提高0.26个百分点。这是长度和batch的组合对照，其时间开销放在7.2。

LoRA秩与注入模块。 保持alpha/r＝2：

配置	注入模块	r / alpha	可训练参数	验证Macro-F1
B00	q/v	8 / 16	1605632	90.95%
R01	q/v	16 / 32	3211264	91.05%
T01	q/k/v/o	8 / 16	3211264	91.39%

q/v秩翻倍，可训练参数翻倍，F1仅提高0.10个百分点。T01与R01可训练参数相同，扩大模块覆盖比只增大q/v秩高0.34个百分点，因此选择T01补种子43、44。其余参数证据如下：

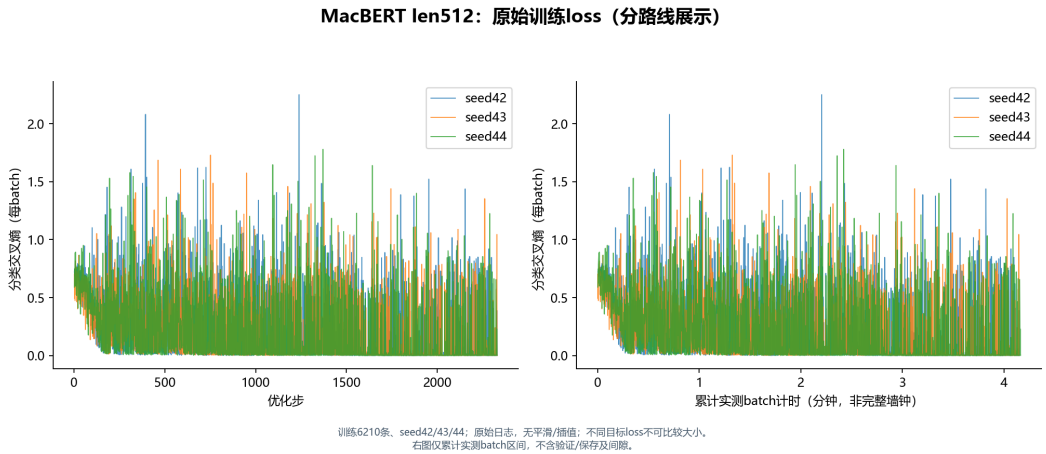
对照	验证结果	解释与取舍
BERT类别加权	256不加权90.62%，加权90.72%；负面召回87.70%→89.75%，正面93.80%→92.86%	改善少数类检出，也牺牲部分正面召回；512＋加权未测试
BERT训练预算	最多3轮90.62%；5轮90.79%	小幅收益约0.18个百分点；总步数也改变调度，耗时见7.2
BERT部分冻结	全参90.62%；冻结嵌入及底6层89.86%	可训练参数102269186→43119362；两组学习率也不同，工程取舍见7.2
LoRA学习率	5e-5 / 1e-4 / 3e-4：90.56% / 90.95% / 90.07%	保留1e-4
LoRA warmup	0.05 / 0.10 / 0.20：90.95% / 90.95% / 90.22%	保留基准0.10，同分不代表逐条预测相同
LoRA衰减	q/v linear90.95%、cosine91.21%；T01 linear91.39%	cosine改善基准，但最终完整候选T01仍最高；T01＋cosine未测
LoRA dropout	0.02 / 0.05 / 0.10：90.68% / 90.95% / 90.81%	保留0.05，收益小于本次模块调整

上述连同TF-IDF、BERT学习率 / 长度和LoRA秩 / 模块，共对应十二项已确认参数结论。最终采用char_1_3、MacBERT全参len512/lr2e-5、LoRA T01。搜索为有限单种子候选，优胜者补43、44，没有把未运行组合的收益相加。完整条件见参数结论。

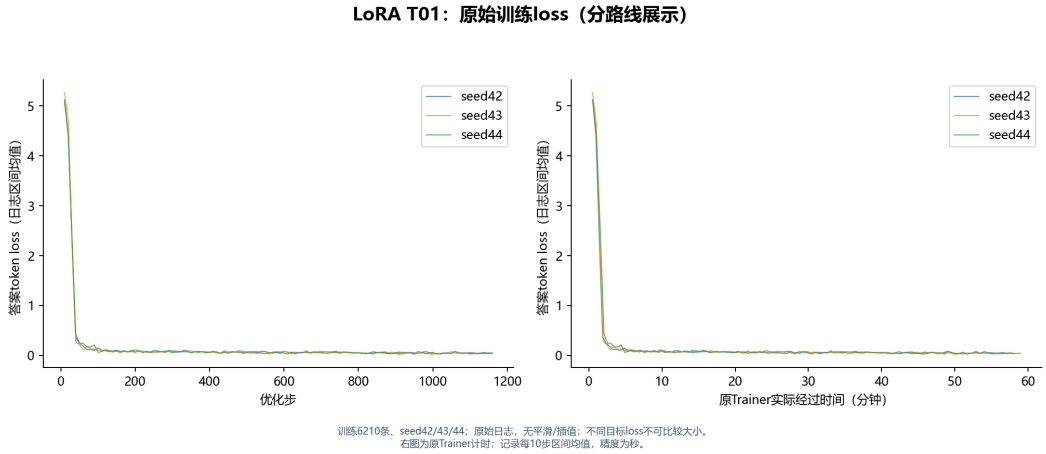
附录D 原始训练曲线、混淆矩阵及迭代

C. 运行日志、曲线与迭代记录

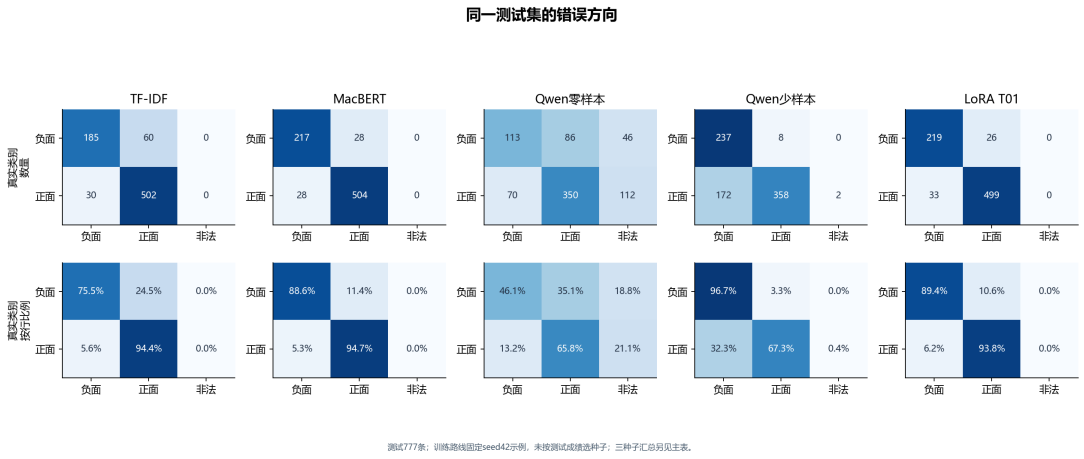
正文4.4—4.5已展示原始日志及逐轮验证过程；本附录保留完整过程图和Git阶段记录。BERT与LoRA的loss定义不同，按路线分图，不把不同损失的数值高低当作方法优劣。



图A1 BERT真实逐batch loss及累计batch实测时间，不平滑；时间轴不包含全部保存等区间，不写成完整墙钟耗时。



图A2 LoRA真实每10步loss记录及Trainer耗时，三个种子分别保留，不与BERT loss绝对值比较。



图A3 显示原始计数、行比例及非法输出列；图内代表运行不能当作三种子平均矩阵，主表仍按各种子指标平均。完整图表见正式图表总览。

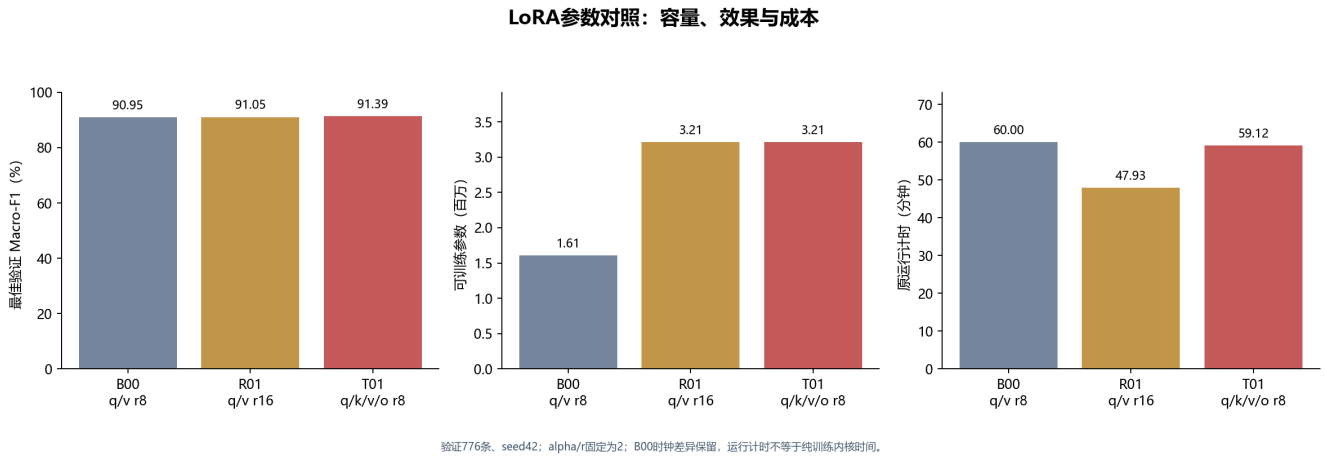
日期	推进内容	可核查证据
2026-10-23	数据清洗、前缀碰撞确认、分层划分与冻结	data/manifests/manifest.json、reports/data/v1-20261023/validation_report.md
2026-10-26	LoRA十组搜索、T01补种子与失败批次保留	results/qwen17-comparisons/及configs/methods/lora-frozen.json
2026-10-28	基线重跑、融合、统一预测与评估	results/bert-tfidf-20261028-140359/执行记录.md、docs/integration/执行验收记录.md；提交340c5dd、6ff484a

日期	推进内容	可核查证据
2026-10-28	正式对比、382条AI辅助归因与图表审计	comparison-formal-20261028-03；提交c1bab6f
2026-10-29	九例与模型参数解释确认、环境补采、适配器图	case-confirmed-20261029-01、conclusions-confirmed-20261029-01；提交2ef5457
2026-10-29	汇总证据并完成课程项目报告	本目录及docs/报告素材/；本报告与Git记录

最后一行不预填未来提交号。Git历史用于证明阶段推进，训练原发生时间仍以各运行记录为准。当前有原始日志、训练曲线及2026-10-29真实Cherry Studio难例对比界面，见reports/demo/cherry-ui-20261029-01/；不将演示界面称为训练现场截图。

附录E 工程成本、许可与AI使用核查

具体对照	已记录成本	对应效果证据
TF-IDF字符2—4 / 1—3 / 2—5 / 词1—2	拟合5.80 / 6.03 / 8.66 / 8.57秒	验证Macro-F1见5.5；char_1_3更优且特征更少
MacBERT长度128 / 256 / 512	完整运行153.43 / 201.94 / 297.94秒	batch为16 / 16 / 8；512比256约多48%时间，F1高0.26个百分点
MacBERT最多3 / 5轮	201.94 / 312.52秒	多约55%时间，验证F1高约0.18个百分点
MacBERT全参 / 部分冻结	201.94 / 131.97秒	少约35%时间，验证F1低约0.76个百分点；学习率也不同
LoRA B00 / R01 / T01	适配器权重6.44 / 12.86 / 12.87MB	R01与T01参数相同，T01验证F1高0.34个百分点



图E1 验证集参数对照及工程开销；图源和数值不变，因含成本维度归入工程成本附录E。不是测试集选优。

7.5 数据许可、隐私与使用范围

项目使用ModelScope公开的AiNiklaus/ChnSentiCorp酒店评论数据。固定版本数据卡标记Apache License 2.0；上游说明注明评论来自携程、原ChnSentiCorp_htl由谭松波整理，并作文件整合、标签转换和去重。上游CSV经下载核对，其SHA256与冻结来源一致。来源、标签映射和许可标记已有依据；未查到独立上游LICENSE文件，逐条评论的独立再分发授权链仍未核实，历史清单redistribution_verified=false保留。许可证据见核查说明。模型许可另按模型来源注明。

本项目按公开数据集原内容使用，不额外脱敏，保持冻结正文、标签、划分与原预测一致。规则扫描全部7,763条保留评论，命中9条、11处联系方式候选：训练4条、验证2条、测试3条；包含手机号式号码、固定电话和QQ账号格式，部分号码重复。AI核对了这些命中上下文；规则扫描仅覆盖所列联系方式格式。新增核查文件只记录ID、位置、类别及不含身份细节的说明，报告只引用已确认案例的必要片段；已公开数据及派生副本没有批量脱敏替

换。因而本项目的实际做法是“公开来源、原样使用并披露检查结果”，不写成“数据不含个人信息”或“已经全库脱敏”。这一处理沿用已确定的数据使用方案。

LoRA使用SwanLab cloud模式。读取最终种子42 / 43 / 44三个本地备份，共7,638条记录，实际包含训练与验证指标、硬件监控、终端日志、配置及环境元数据；不是只有loss等指标。按完整可见文本、32字符前缀及联系方式匹配规则，三个备份和配置均未发现相应评论匹配；记录中的API密钥字段为占位符。该结论限于本地镜像，远程账号不在本次本地备份检查范围内。原零 / 少样本脚本采用offline，和LoRA分别说明。字段与哈希见审计记录。

7.6 AI使用声明

本项目使用Codex辅助工程实现、证据核查与报告表达；未完整记录会话模型版本，因此按工具名披露。AI参与范围及验证方式如下。

使用环节	AI辅助的具体内容	人工输入、修改与验证
文档与技术选型	查阅Transformers、PEFT、LLaMA-Factory等资料，整理参数候选和方法说明	刘广徽确定技术路线、显存约束及普通LoRA范围，补充B站教程和WebUI选型动机；以最终配置核对实际执行
数据与格式转换	辅助编写JSONL / Alpaca转换、长度与重复检查、哈希记录代码	冻结种子67、ID和标签；核对7766＝7763＋1空文本＋2重复前缀，核查三路线输入与固定示例
工程与训练记录	编写 / 调试统一CLI、输出适配、配置和日志接口，排查报错	杨函齐负责MacBERT与TF-IDF，李嘉谊林负责零 / 少样本，刘广徽负责LoRA与融合；采用实际运行记录核对超参数、训练与检查点
统一评估与图表	对齐严格标签解析、Macro-F1等指标、种子汇总、延迟统计和图表脚本	从原始逐样本预测独立重算，核对源文件SHA256；loss图只读取真实日志，不补造训练曲线
错例整理与解释	对382条错例按试标规则辅助分类，整理不同模型输出和候选归因	刘广徽试标20条，逐例审核九个正式案例，修订任务适应性解释；124条探索性材料保留未定稿状态，不计人工归因比例
报告与交付	按任务书整理已有结论、公式、图注、个人分工、README及复现入口	人工确认八项模型与十二项参数结论；用原始配置、指标和日志逐项核验文字中的数字，个人工时由组长提供
跨机复验与诊断	核对两机预测、编写数值记录与验证诊断、整理BF16局限和双机主结果	保留原权重与成绩，逐项核验输入token、得分、buffer及重复运行；组长确认将硬件差异纳入主结论，停止进一步补测
新机失败定位与修复（2026-10-29）	读取回传日志，补全158项依赖，修复预检、路径、下载和差异记录	用户提供失败证据；原机验证与组员新机验收分别留证，不更换实验协议

AI曾参与参数候选、方案整理和结果文字组织，以上范围如实披露。实验选择和结果判断由项目成员负责：没有把AI建议当作已经执行的实验，没有把软件检查当作模型效果，也没有把探索性AI标注统计写成人工金标。代码及文字中的具体事实以原始日志、配置、逐样本输出和成员提供的信息为准。

附录F 复现、源码与参考来源

A. 复现指南

A1 现有预测的离线指标复现。 在完整仓库根目录使用Python≥3.11：

```
python -S reproduce.py
```

入口检查47份冻结输入、6210 / 776 / 777划分、16份验证 / 测试记录和11份最终测试，重算三个训练种子均值并与主表比较。输出全新results/reproduction/<唯一ID>/，状态通过且指标差为0才算完成。完整图表使用已锁定的分析环境运行python reproduce.py --analysis，生成22组图。独立目录及CI离线核查已通过，新机复现完成状态单独登记。当前提交ZIP按任务书排除数据集和权重；包内python src/run.py会按固定Git提交和SHA256下载必要证据到独立工作目录，再调用相同入口，详见包内README。

A2 真实模型预测入口。 按根README获取权重与适配器，将configs/paths.example.json复制为configs/paths.local.json并填写自己的数据、模型和工具地址，然后在模型环境执行示例命令：

```
python -m src.cli predict --method qwen_lora --seed 42 --split test --output results/local/new-machine-lora42-001
```

每次完整测试输出777条predictions.jsonl、metrics.json、config.json与status.json，并保留固定200条延迟记录。单个种子命令用于逐项核查，五方案主表包含三种子训练路线和两项确定性提示结果；完整队列命令为python src/run.py --models --paths src/project/configs/reproduce-models.local.json。2026年10月30日最新4060回传：已有预测重算通过，真实模型11次各777条完整，85条输出差异、61条解析标签差异，最大指标差0.020592。16条验证诊断定位到首步数值输出与token排序变化，三种受控配置仍未跨机完全一致。完整运行与历史精确对照分别报告，Qwen差异作为硬件稳定性实验结果。

B. 代码结构说明

```
NLP/
├── README.md # 安装、路径与统一命令
├── configs/ # 数据、方法、评估和分析配置
├── data/processed/ # 冻结JSONL、Alpaca及索引
├── data/manifests/ # 来源、划分、子集与哈希
├── src/cli.py # 统一工程入口
├── src/adapters/ # 导入、提示恢复及模型推理
├── src/evaluation/ # 严格解析、指标与完整性检查
├── src/legacy/ # 三方既有训练与接入代码
├── scripts/ # 分析、审计与图表生成
├── tests/ # 软件集成检查
├── results/ # 预测、指标、运行索引和日志证据
├── reports/ # 审计、图表及确认版分析
└── docs/ # 人员文档、交接与报告材料
```

训练框架、权重和大检查点保留在各人的工具工作区，由本地路径配置关联。协作仓库不要求成员使用作者的绝对地址。

D. 数据来源与许可说明

来源：ModelScope AiNiklaus/ChnSentiCorp。源文件ChnSentiCorp_htl_all.csv，大小2904858字节，SHA256为1d414b9c65caf3a836abdb4efded621968502ad3338e1a9d885ae131c86083f0。预检核对内容revision为eec2cd0294bbd8711cbbbaab13ec4c2320d7f815，原下载revision未知；标签与上游CSV核对依据存于数据清单。

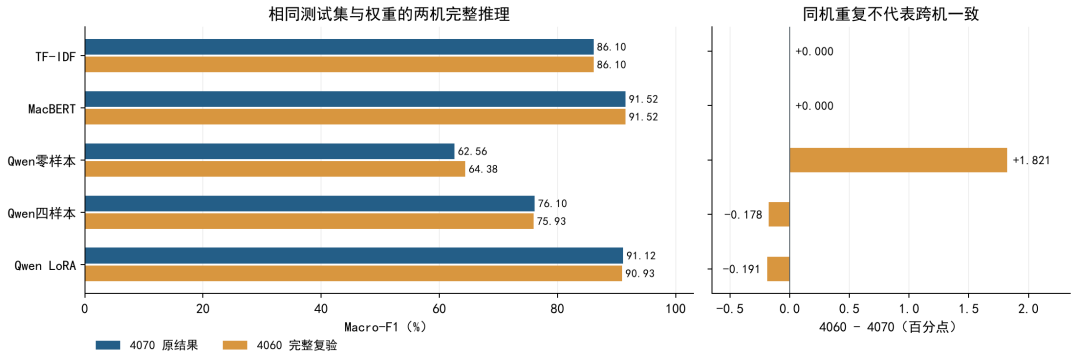
项目训练 / 验证 / 测试JSONL哈希分别为a37fa5d7139c68fa2fc39bbcff0a9ae3d2beb3e7268fbd25a646b4aa65a3e22f、eae1c55c43f7121c4e24b4fb4634e0ea3406cbd99fe9cd05ca9151c253c7fe64、3df19229abb59d1868a7735b98f42fd799883c22ec37aa8a1760cc2266fb1996。平台许可标记与来源核查见第7.5节，独立再分发授权链未核实，保持清单redistribution_verified=false的事实。

参考资料与内部证据

1. scikit-learn: Text feature extraction。
2. Cui等，2020，Revisiting Pre-trained Models for Chinese Natural Language Processing；HFL模型页。
3. Qwen3官方介绍；Qwen3-1.7B模型页。
4. Hu等，2021，LoRA: Low-Rank Adaptation of Large Language Models。
5. LLaMA-Factory官方项目。
6. 参考的B站LoRA微调教程（BV1waZ2YDEcp）。标题与作者未核实，当前按视频号引用。
7. 九案例至技术选型证据汇总、正式对比索引、数据清单。

报告数值与原始记录对应，源码与资源链接见README。

附录G 跨机主结果与BF16数值诊断



训练路线各3种子取均值；提示各1次，每次777条。原始指标保留，不混合两机结果。

图G-1 相同冻结测试集、相同权重和协议的两机完整推理；5条路线的F1排名一致，但零样本波动明显。成本仍采用E01，不把两机延迟混合。逐运行数值和差异文件均保留。

验证诊断配置	输入不同 / 16	首步得分不同 / 16	生成不同 / 16
原BF16路径	0	16	1
受控Flash SDPA	0	14	1
受控Math SDPA	0	14	1

模型文件哈希、数值buffer和非设备运行字段一致；4070为36个SM，4060为24个SM，计算能力均8.9。4060重复两次的三配置共48组配对均逐步得分与生成ID一致。此处只诊断零 / 四样本各8条验证评论，不包含LoRA，也不用于重新选参。

样本5500真实负面。4070原路径首token为16（“1”），4060为15（“0”）；4060后续解释使输出非法。两机最高分与次高分差均0.25，次高均为100345；0.25不是正负标签间分差。差异在首步数值输出和候选排序中已观察到，尚不能唯一定位到某个GPU内核或推断FP32一定消除差异。

正式4060推理为11次、每次777条：85条输出不同，其中61条改变解析标签。小规模诊断未修改正式状态completed_with_differences；完整性和逐token一致性分别解释，Qwen硬件差异纳入主结论。官方数值原理参考PyTorch Numerical accuracy；复核记录见reports/reproduction-gpu-diagnosis-20261030-02。

FP32仅完成4070上的16条验证试测，未进行LoRA、全量测试或4060 FP32对照，不构成提高精度改善一致性的结论；正式主表仍为BF16结果。