固定200条评论：延迟分布与尾延迟

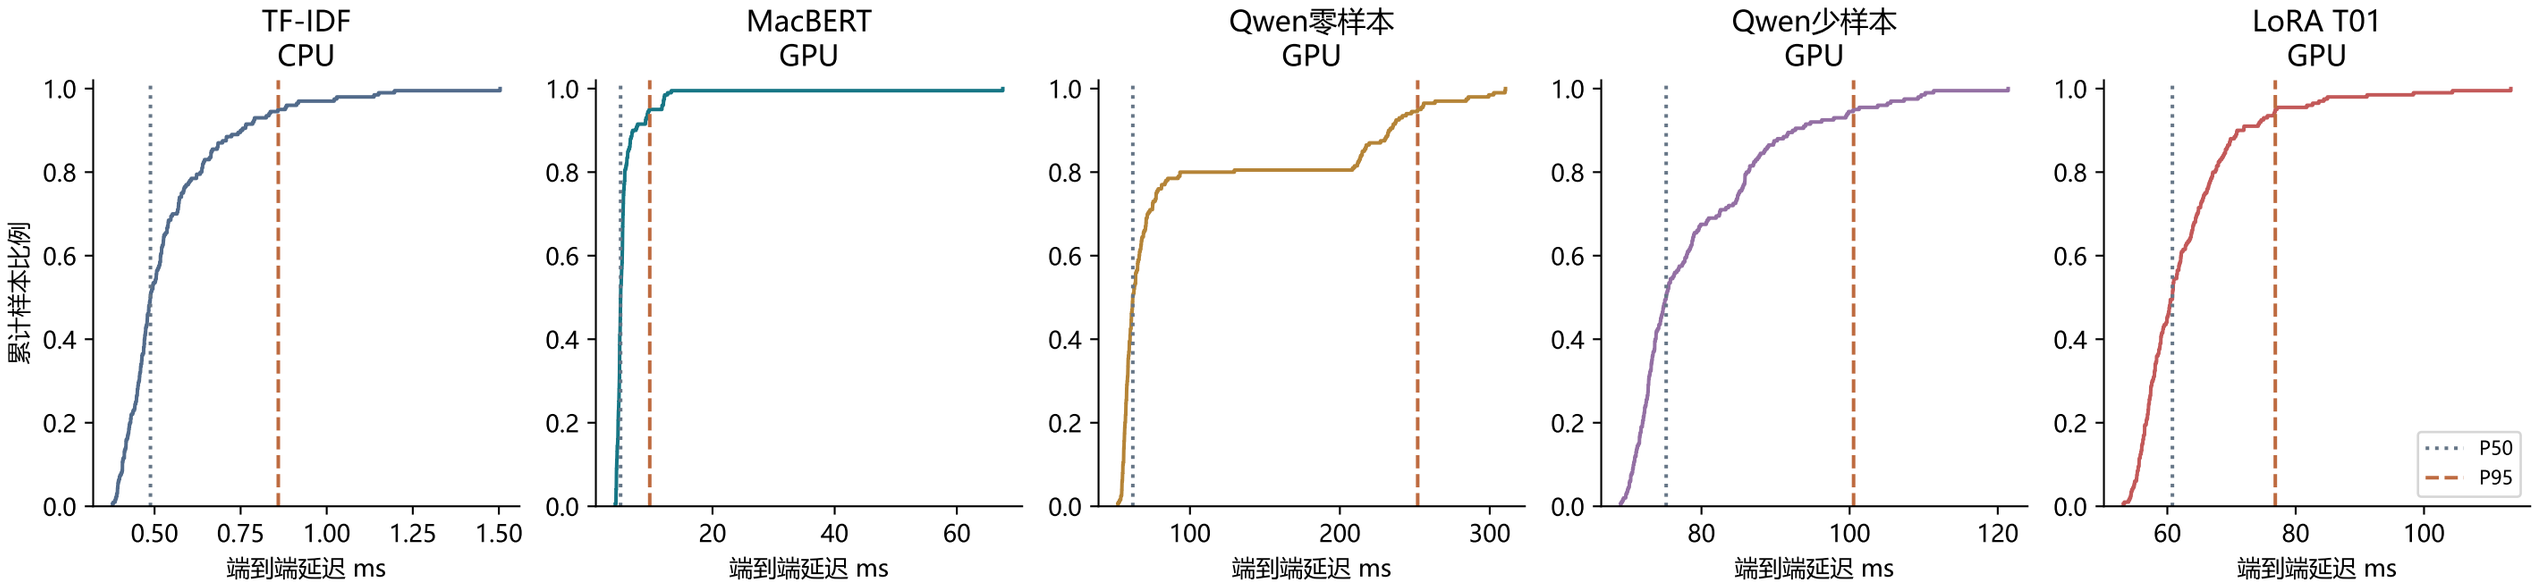

各图横轴不同；20条预热、batch1、含分词/传输/推理/解析，不含加载/读盘；训练模型展示seed42。