配对差异：固定模型下的测试样本不确定性

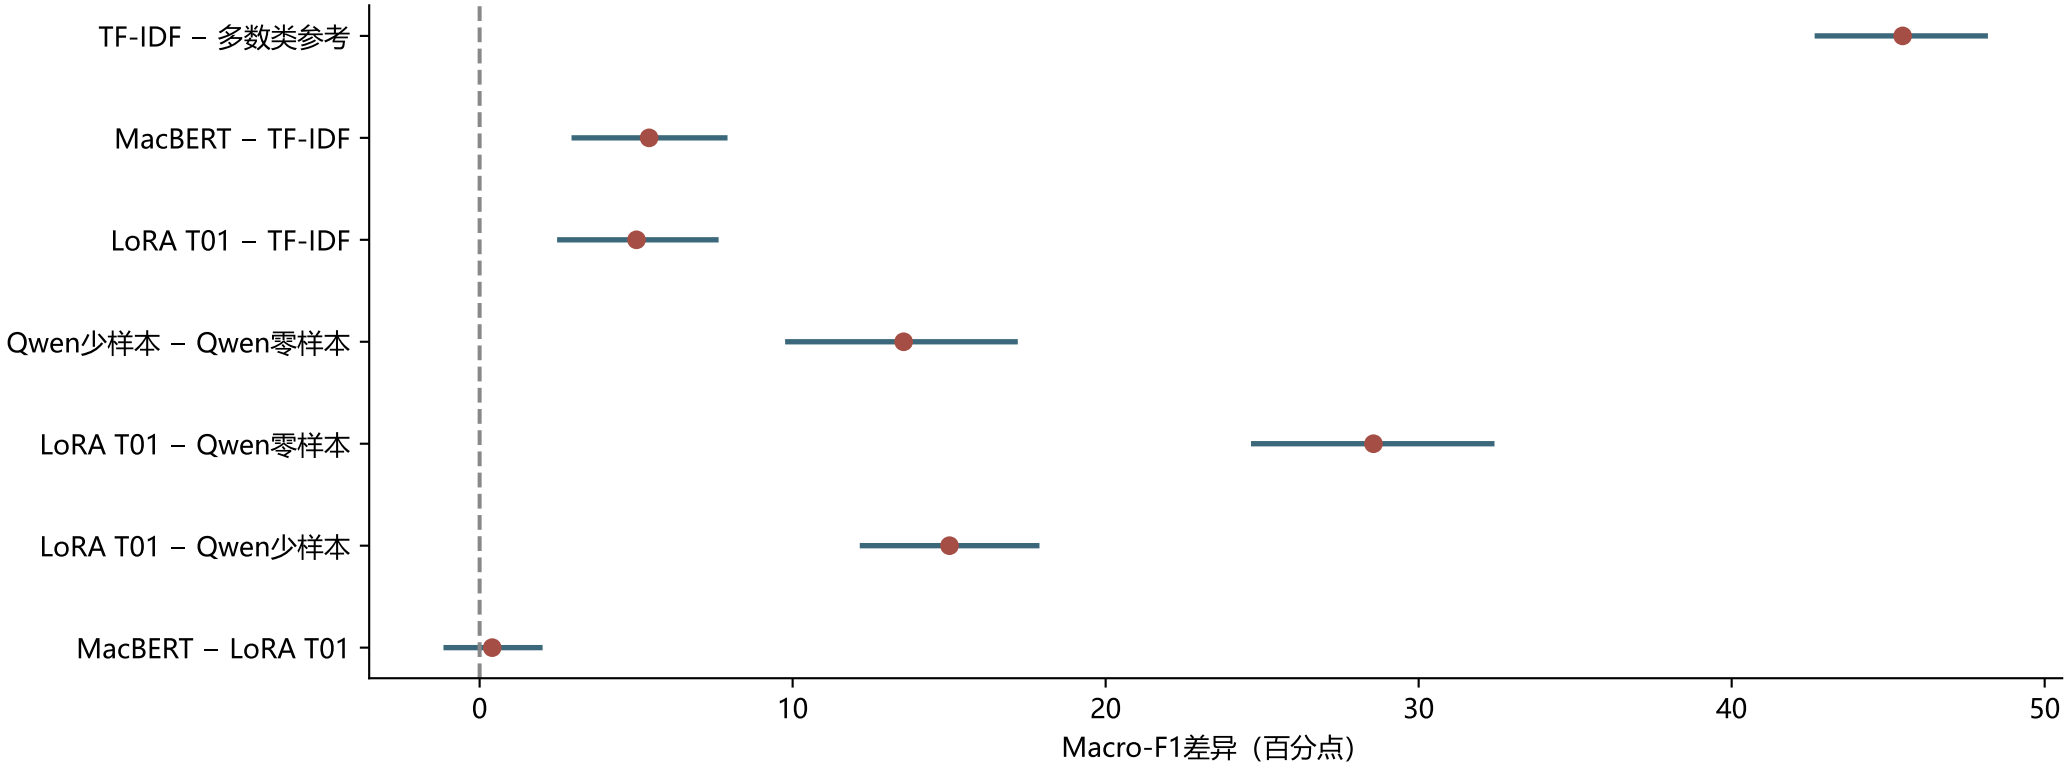

5000次按真实类别分层的配对bootstrap、95%逐项百分位区间；种子先分别算F1再平均；事后探索性分析。